

1. COMPAS – Sistema judicial con sesgos raciales

¿Qué es COMPAS?

COMPAS (Correctional Offender Management Profiling for Alternative Sanctions) es un algoritmo desarrollado por la empresa Northpointe (hoy Equivant) para **predecir la probabilidad de que un acusado vuelva a cometer un delito**.

Es utilizado en tribunales de Estados Unidos como parte de evaluaciones de riesgo para decisiones como:

- fijación de fianza
- sentencias
- libertad condicional

El problema

En 2016, una investigación de ProPublica reveló que COMPAS presentaba:

- Los acusados afroamericanos eran catalogados **erróneamente como de "alto riesgo"** casi **el doble** de veces que acusados blancos.
- Acusados blancos eran etiquetados como "bajo riesgo" con mucha mayor frecuencia, incluso en casos de reincidencia real.
- El algoritmo no era explicable: la empresa consideraba su modelo **propietario**, por lo que **jueces, abogados y acusados** no podían revisar cómo funcionaba.

Impacto real

Personas recibieron sentencias más duras basadas en predicciones sesgadas, afectando libertades individuales y perpetuando desigualdad racial.

2. Amazon Hiring Tool – Algoritmo de selección que discriminaba mujeres

¿Qué era la herramienta?

Amazon desarrolló un sistema interno de IA en 2014 para automatizar la **evaluación de currículos** y seleccionar los mejores candidatos para roles técnicos.

El problema

El sistema fue entrenado con **10 años de currículos históricos**, en su mayoría de **hombres**, porque el sector tecnológico está históricamente dominado por ellos.

Como resultado, el algoritmo “aprendió” a **preferir candidatos masculinos**:

- Penalizaba palabras como “women’s” (por ejemplo “women’s chess club captain”).
- Bajaba el puntaje de universidades donde había mayor participación femenina.
- Beneficiaba patrones asociados históricamente a hombres.

Incluso cuando Amazon eliminó explícitamente la variable “género”, el modelo seguía usando **señales indirectas** (proxy variables).

Impacto real

El sistema fue cancelado, pero muestra cómo los modelos basados en datos históricos pueden **reproducir y amplificar discriminación sistémica**.

3. Clearview AI – Reconocimiento facial sin consentimiento

¿Qué es Clearview AI?

Clearview es una empresa que desarrolló un sistema de **reconocimiento facial a gran escala**, usado por agencias policiales y de seguridad.

Su base de datos contenía **miles de millones de imágenes extraídas sin permiso** de redes sociales, sitios web, cámaras públicas y otras fuentes.

El problema

- Las imágenes fueron recolectadas **sin consentimiento** de los usuarios.
- Las personas no sabían que sus rostros estaban siendo almacenados en un sistema policial.
- El algoritmo se usó **de forma opaca**, sin control público ni mecanismos de auditoría.
- Tenía tasas más altas de error en mujeres, niños y personas de piel oscura.
- Varias jurisdicciones declararon su uso como **ilegal** (Reino Unido, Canadá, Australia).

Impacto real

- Personas inocentes fueron identificadas erróneamente en investigaciones policiales.
- Países prohibieron el sistema.
- La empresa enfrentó demandas por violación de privacidad.

 Por qué estos casos son fundamentales en una clase de ética en IA

1. **Son reales**, no hipotéticos.
2. **Demuestran fallos** en distintas etapas: datos, modelos, uso y regulación.
3. Ilustran claramente **principios éticos violados**.
4. Permiten conectar ética con **impactos concretos en la vida de las personas**.
5. Dan pie a debates potentes en clase sobre responsabilidad, regulación y diseño ético.